

# AlphaTech Analyzer

Proyecto de Análisis Estadístico Financiero

## Informe Estadístico

Análisis Cuantitativo del Sector Tecnológico

NASDAQ-100 | 2018–2024

**Universo de análisis:** 30 empresas tecnológicas NASDAQ-100

**Período temporal:** Febrero 2018 – Diciembre 2024

**Frecuencia de datos:** Mensual (hasta 83 observaciones por empresa)

**Variables principales:** Precio Ajustado, Volumen, Retorno Log.

**Observaciones totales:** 2,403 registros

# Índice

---

<b>Resumen Ejecutivo</b>	<b>2</b>
<b>1. Análisis Exploratorio de Datos (EDA)</b>	<b>3</b>
1.1. Estructura del Conjunto de Datos . . . . .	3
1.2. Análisis de Valores Faltantes . . . . .	4
1.3. Distribución de Retornos Financieros . . . . .	6
1.3.1. Distribución por Empresa: Análisis Comparativo . . . . .	7
1.3.2. Volatilidad por Empresa . . . . .	8
1.4. Relación Riesgo-Retorno . . . . .	9
1.5. Evolución Temporal de Precios . . . . .	11
1.5.1. Series Normalizadas: Comparación Multi-Activo . . . . .	11
1.6. Análisis de Correlación . . . . .	13
1.7. Detección de Valores Atípicos (Outliers) . . . . .	15
1.8. Análisis de Momentos Estadísticos . . . . .	16
1.9. Análisis de Drawdown . . . . .	18
1.10. Análisis de Cambio Estructural: Pre/Post COVID-19 . . . . .	20
1.11. Síntesis del Análisis Exploratorio . . . . .	23
<b>Referencias Bibliográficas</b>	<b>24</b>

## Resumen Ejecutivo

### Visión General del Estudio

Este informe presenta un análisis estadístico exhaustivo de **30 empresas del sector tecnológico** pertenecientes al índice NASDAQ-100 durante el período **febrero 2018 – diciembre 2024**. El estudio comprende **2,403 observaciones mensuales** y abarca desde la exploración inicial de los datos hasta análisis de riesgo, correlación y cambio estructural asociado a la pandemia de COVID-19.

#### Principales Hallazgos

- ✓ El 73.3% de empresas presenta **colas pesadas** (leptocurtosis)
- ✓ Correlación promedio de  $\rho = 0,40$ , máxima de  $\rho = 0,72$
- ✓ El 10.7% de empresas muestra **cambio estructural** post-COVID
- ✓ Tesla y Nvidia con MDD superior al 60%

#### Implicaciones Prácticas

- ▲ Modelos gaussianos **subestiman** riesgos de cola
- ▲ Diversificación intra-sectorial tiene **beneficio limitado**
- ▲ Gestión de riesgo debe incorporar **métricas de drawdown**
- ▲ Análisis de régimen es **esencial** en contextos de crisis

# 1 Análisis Exploratorio de Datos (EDA)

## ◇ Concepto Clave

El **Análisis Exploratorio de Datos** (EDA, *Exploratory Data Analysis*) constituye el pilar fundamental de cualquier investigación estadística rigurosa. Introducido por John W. Tukey en su obra seminal *Exploratory Data Analysis* (Addison-Wesley, 1977), este enfoque metodológico prioriza la comprensión profunda de los datos antes de aplicar modelos formales.

*“El análisis exploratorio es trabajo detectivesco numérico — o conteo, o representación gráfica. [...] Los gráficos son esenciales.”*

— J. W. Tukey, *Exploratory Data Analysis*, p. 1

En el contexto del análisis financiero cuantitativo, el EDA cumple funciones críticas:

1. **Validación de integridad:** Identificación de valores faltantes, inconsistencias y errores de captura que podrían comprometer análisis posteriores.
2. **Caracterización distribucional:** Evaluación de momentos estadísticos, detección de asimetrías y cuantificación de comportamientos extremos.
3. **Descubrimiento de patrones:** Revelación de estructuras de correlación, dependencias temporales y agrupamientos naturales.
4. **Verificación de supuestos:** Contraste empírico de hipótesis requeridas por modelos paramétricos (normalidad, homocedasticidad, estacionariedad).

## 1.1 Estructura del Conjunto de Datos

El estudio se fundamenta en un **panel de datos** (datos longitudinales) que combina la dimensión temporal con la transversal, permitiendo capturar tanto la evolución individual de cada empresa como las dinámicas comunes del sector.

### Panel de Datos

Un **panel de datos** (también denominado datos longitudinales) es una estructura que combina:

- **Dimensión transversal:** Múltiples entidades (empresas, individuos, países)
- **Dimensión temporal:** Observaciones repetidas en el tiempo

Formalmente, para  $N$  entidades observadas en  $T$  períodos, el panel contiene  $N \times$

$T$  observaciones potenciales. Cuando todas las combinaciones están presentes, se denomina **panel balanceado**.

Cuadro 1: Estructura del Panel de Datos Analizado

Característica	Valor	Descripción
Empresas ( $N$ )	30	Tecnológicas NASDAQ-100
Período	Feb 2018 – Dic 2024	Aproximadamente 7 años
Frecuencia	Mensual	Último día hábil de cada mes
Observaciones	2,403	Panel desbalanceado (4 empresas con IPO posterior)
Variables del Panel:		
Date	datetime	Fecha de observación
Company	string	Identificador de empresa
AdjClose	float (USD)	Precio ajustado por dividendos/splits
Volume	int	Volumen mensual negociado
Return	float	Retorno logarítmico mensual

Retorno Logarítmico

El retorno logarítmico (también denominado retorno continuo) se define como:

$$r_t = \ln \left( \frac{P_t}{P_{t-1}} \right) = \ln(P_t) - \ln(P_{t-1}) \tag{1}$$

donde  $P_t$  representa el precio ajustado en el período  $t$ . Esta transformación presenta ventajas sobre los retornos simples:

- **Aditividad temporal:**  $r_{t \rightarrow t+n} = \sum_{i=0}^{n-1} r_{t+i}$
- **Simetría:** Movimientos equivalentes producen retornos simétricos
- **Propiedades estadísticas:** Distribución más próxima a la normal

1.2 Análisis de Valores Faltantes

La presencia de datos ausentes constituye una problemática ubicua en el análisis empírico. Su tratamiento inadecuado puede introducir sesgos sistemáticos y comprometer la validez de las inferencias estadísticas.

Taxonomía de Datos Faltantes

La literatura estadística, fundamentada en el trabajo de Donald B. Rubin (*Biometrika*, 1976), distingue tres mecanismos generadores de datos ausentes:

1. **MCAR** (*Missing Completely At Random*): La probabilidad de ausencia es independiente de cualquier variable. Representa el escenario más favorable.

$$P(M|Y_{obs}, Y_{miss}) = P(M)$$

2. **MAR** (*Missing At Random*): La probabilidad depende únicamente de variables observadas.

$$P(M|Y_{obs}, Y_{miss}) = P(M|Y_{obs})$$

3. **MNAR** (*Missing Not At Random*): La probabilidad depende del propio valor no observado. Genera sesgo difícil de corregir.

En mercados financieros, las causas típicas incluyen: feriados bursátiles, suspensiones de cotización, IPOs posteriores al inicio del período.

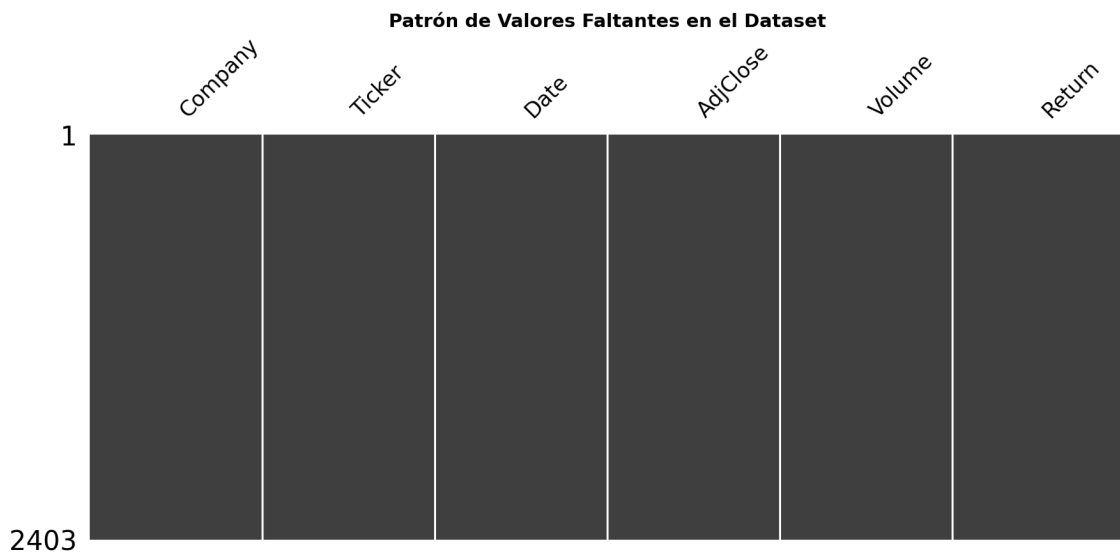


Figura 1: Matriz de completitud del dataset. Cada fila representa una observación temporal y cada columna una variable. Las áreas sólidas indican datos presentes; franjas blancas revelarían patrones de ausencia. El dataset analizado presenta alta completitud.

### ⊙ Resultado

El análisis de valores faltantes del panel revela:

- **Todas las columnas:** 0 % de datos faltantes (Company, Ticker, Date, AdjClose, Volume, Return)
- **Empresas con menos de 83 observaciones:** Palantir (51), Snowflake (51), Cloudflare (63), Spotify (80)
- **Causa:** IPOs posteriores al inicio del período de análisis (no datos faltantes, sino inexistentes)

El dataset presenta **calidad excelente** para análisis sin necesidad de imputación.

### 1.3 Distribución de Retornos Financieros

La caracterización distribucional de los retornos constituye un pilar fundamental del análisis financiero cuantitativo. Las propiedades de esta distribución determinan la validez de modelos de valoración y métricas de riesgo.

#### Hechos Estilizados de Retornos Financieros

La investigación empírica, documentada extensamente por Cont (*Quantitative Finance*, 2001) y Campbell, Lo & MacKinlay (*The Econometrics of Financial Markets*, Princeton, 1997), ha identificado regularidades que distinguen los retornos financieros de la distribución normal:

1. **Colas pesadas** (*fat tails* / leptocurtosis): Eventos extremos de  $\pm 4\sigma$  o más ocurren con frecuencia significativamente mayor a la predicha por la normal.
2. **Asimetría negativa**: Las caídas abruptas tienden a ser más pronunciadas que las subidas equivalentes, especialmente durante episodios de estrés.
3. **Agrupamiento de volatilidad** (*volatility clustering*): Períodos de alta volatilidad tienden a persistir. Formalizado en modelos ARCH/GARCH (Engle, 1982; Bollerslev, 1986).
4. **Efecto apalancamiento**: Correlación negativa entre retornos y volatilidad futura; las caídas incrementan la volatilidad más que subidas equivalentes.

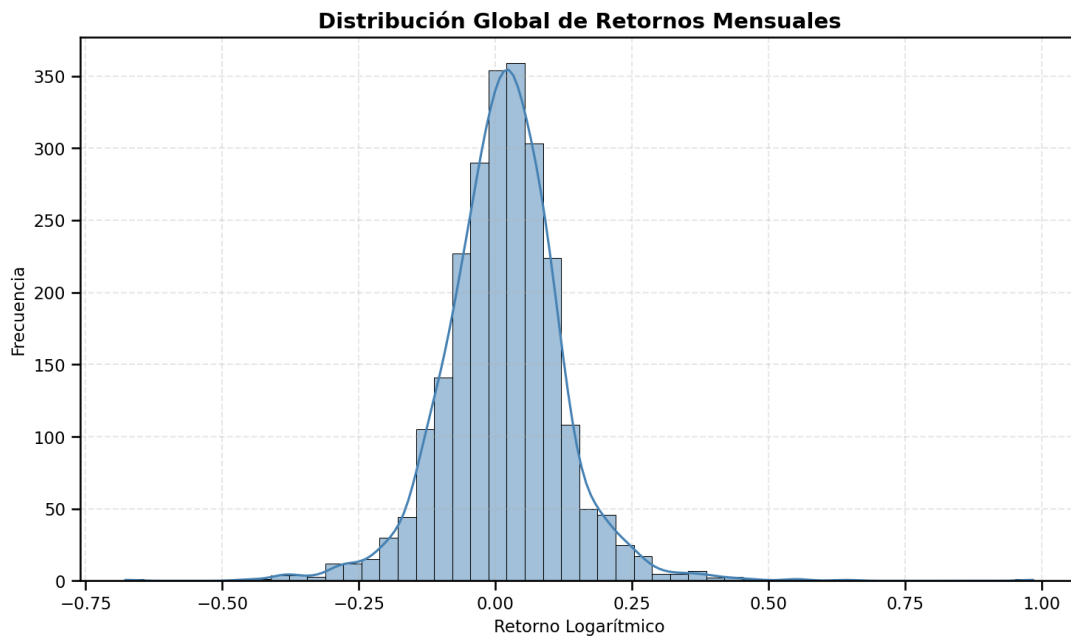


Figura 2: Distribución empírica de retornos mensuales del panel. El histograma representa la frecuencia observada; la curva KDE (*Kernel Density Estimation*) suaviza la distribución. Se observa la característica forma leptocúrtica con colas más pesadas que la normal.

**Nota:**

La distribución agregada de los 2,403 retornos mensuales presenta las siguientes características:

- **Media:**  $\mu = 1,53\%$  mensual
- **Volatilidad:**  $\sigma = 10,84\%$  mensual
- **Asimetría global:**  $\gamma_1 = 0,28$  (sesgo positivo leve)
- **Curtosis global:**  $\gamma_2 = 5,43$  (leptocurtosis pronunciada)

La curtosis de 5.43 implica colas significativamente más pesadas que la distribución normal ( $\gamma_2 = 0$ ), confirmando que los modelos gaussianos subestiman la probabilidad de eventos extremos.

**Estimación de Densidad Kernel (KDE)**

La KDE es un método no paramétrico para estimar la función de densidad de probabilidad:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (2)$$

donde  $K(\cdot)$  es una función kernel (típicamente gaussiana) y  $h$  es el parámetro de ancho de banda (*bandwidth*). A diferencia del histograma, la KDE produce estimaciones continuas y diferenciables.

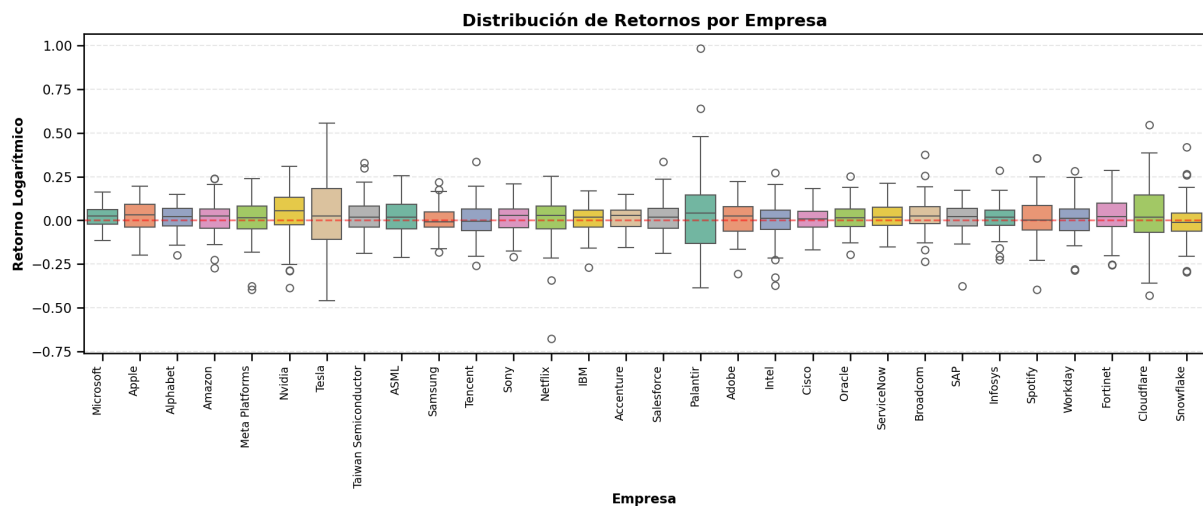
**1.3.1 Distribución por Empresa: Análisis Comparativo**

Figura 3: Diagramas de caja (boxplots) de retornos logarítmicos mensuales por empresa. Cada boxplot sintetiza: mediana (línea central), cuartiles (bordes), rango IQR extendido (bigotes) y outliers (puntos). La línea de referencia en cero facilita identificar sesgo.

El boxplot codifica visualmente la distribución mediante:

$$\text{Mediana} = Q_2 = \text{Percentil}_{50} \quad (3)$$

$$\text{Rango Inter cuartílico} : IQR = Q_3 - Q_1 \quad (4)$$

$$\text{Bigote inferior} = Q_1 - 1,5 \times IQR \quad (5)$$

$$\text{Bigote superior} = Q_3 + 1,5 \times IQR \quad (6)$$

$$\text{Outliers} : x \notin [Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR] \quad (7)$$

El factor 1.5 corresponde a la propuesta original de Tukey; para outliers extremos se utiliza factor 3.0.

## 1.3.2 Volatilidad por Empresa

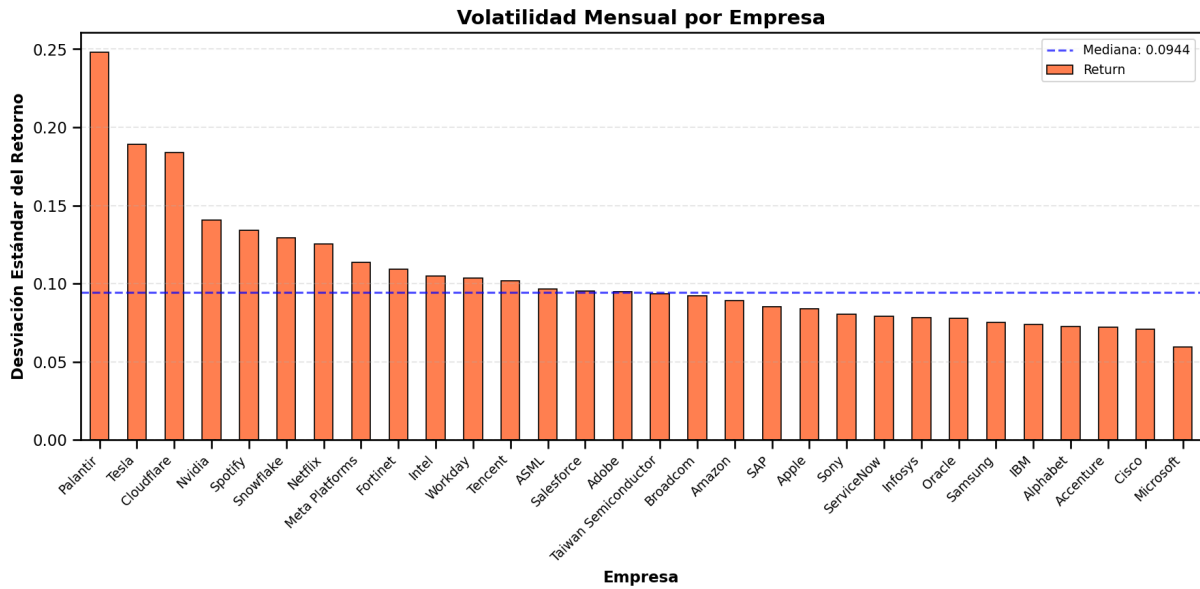


Figura 4: Volatilidad mensual (desviación estándar de retornos) por empresa, ordenada de mayor a menor. La línea horizontal indica la mediana sectorial. Empresas como Tesla y Nvidia exhiben volatilidad significativamente superior al promedio.

## Volatilidad Histórica

La volatilidad representa la dispersión de los retornos y constituye la métrica de riesgo más utilizada en finanzas. Según Hull (*Options, Futures, and Other Derivatives*, Pearson, 2018), la volatilidad histórica se estima como:

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (r_i - \bar{r})^2} \quad (8)$$

Esta métrica está fundamentada en la Teoría Moderna de Portafolios, que asume inversores aversos al riesgo que prefieren menor variabilidad para un mismo retorno esperado.

### Limitaciones de la Volatilidad como Métrica de Riesgo

La desviación estándar presenta deficiencias importantes:

- **Simetría implícita:** Penaliza igualmente ganancias y pérdidas inesperadas
- **Supuesto de normalidad:** Subestima eventos extremos en distribuciones leptocúrticas
- **Mirada retrospectiva:** Volatilidad histórica no predice necesariamente la futura

Métricas complementarias: Value at Risk (VaR), Expected Shortfall (CVaR), Maximum Drawdown.

## 1.4 Relación Riesgo-Retorno

La relación entre riesgo y retorno esperado constituye el axioma central de las finanzas modernas.

### Frontera Eficiente

Harry M. Markowitz formalizó el problema de selección de portafolios como optimización media-varianza en su artículo “*Portfolio Selection*” (*The Journal of Finance*, Vol. 7, No. 1, 1952, pp. 77–91), trabajo por el cual recibió el Premio Nobel de Economía en 1990. La **frontera eficiente** representa el conjunto de portafolios que maximizan retorno para cada nivel de riesgo.

Para un portafolio de dos activos:

$$\sigma_p^2 = w_1^2\sigma_1^2 + w_2^2\sigma_2^2 + 2w_1w_2\sigma_1\sigma_2\rho_{12} \quad (9)$$

El término  $2w_1w_2\sigma_1\sigma_2\rho_{12}$  es la fuente del beneficio de diversificación cuando  $\rho_{12} < 1$ .

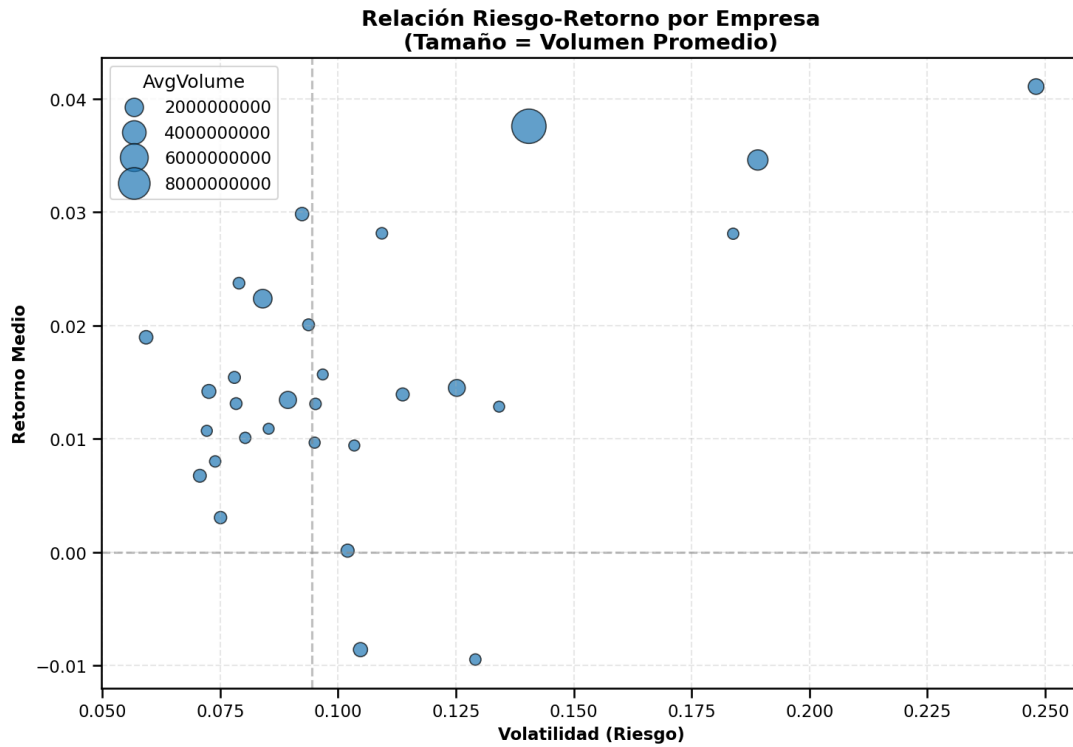
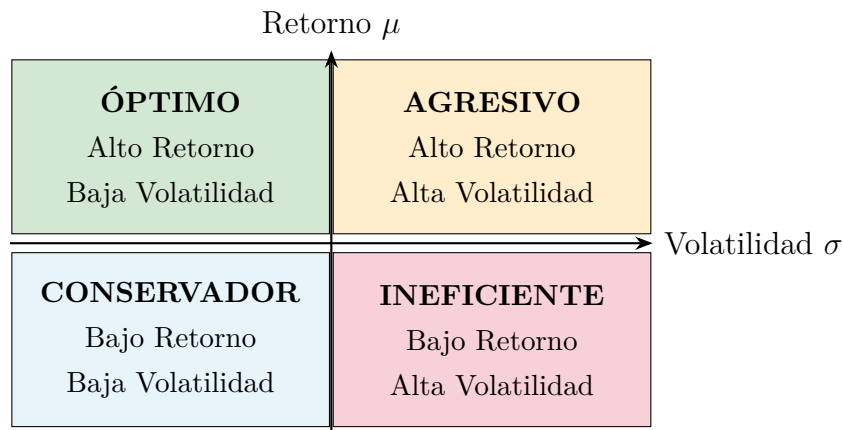


Figura 5: Diagrama de dispersión riesgo-retorno. Cada punto representa una empresa; el tamaño es proporcional al volumen promedio (proxy de liquidez). Las líneas punteadas segmentan el espacio según mediana de volatilidad y retorno cero.



### Ratio de Sharpe

El ratio de Sharpe cuantifica el exceso de retorno por unidad de riesgo:

$$\text{Sharpe Ratio} = \frac{E[R_p] - R_f}{\sigma_p} \quad (10)$$

donde  $R_f$  es la tasa libre de riesgo. Valores  $> 1,0$  se consideran atractivos;  $> 2,0$ , excelentes.

## 1.5 Evolución Temporal de Precios

### Precio Ajustado (*Adjusted Close*)

El precio ajustado incorpora correcciones retroactivas por eventos corporativos:

- **Dividendos:** El precio ex-dividendo cae por el monto distribuido; el ajuste redistribuye hacia atrás
- **Splits:** Una división 2:1 reduce el precio a la mitad; los históricos se ajustan proporcionalmente
- **Derechos y spin-offs:** Otras acciones que modifican acciones en circulación

El uso del precio ajustado es **imperativo** para calcular retornos totales reales.

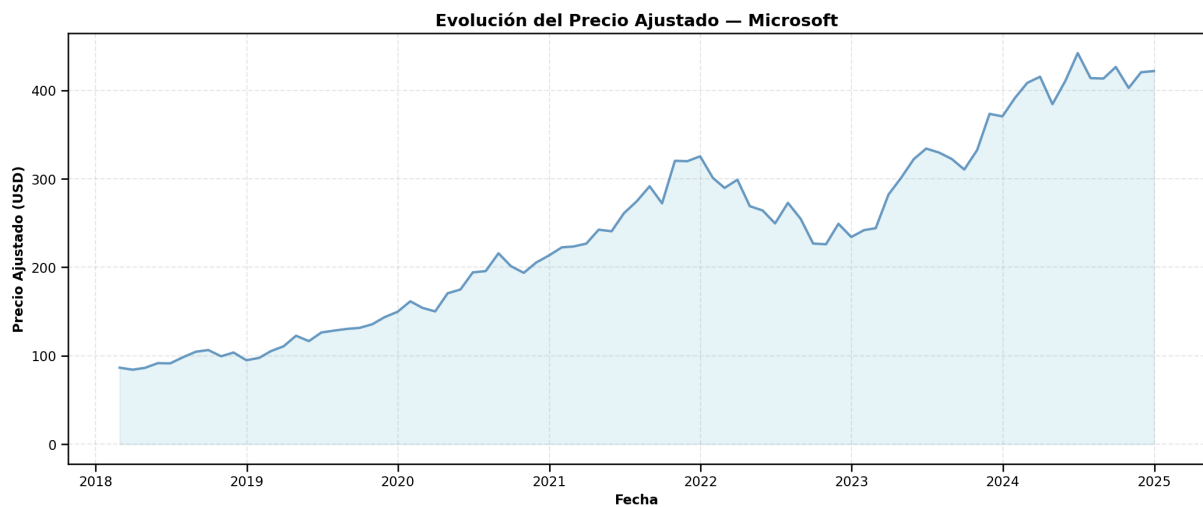


Figura 6: Evolución del precio ajustado de Microsoft (MSFT) 2018–2024. El área sombreada facilita visualización de tendencia. Se observan correcciones durante COVID-19 crash (marzo 2020) y tech selloff (2022).

### 1.5.1 Series Normalizadas: Comparación Multi-Activo

#### Normalización Base 100

Para comparar activos con precios en escalas dispares:

$$P_t^{norm} = \frac{P_t}{P_0} \times 100 \quad (11)$$

Interpretación:

- $P_t^{norm} = 150 \Rightarrow$  Rendimiento acumulado +50 %
- $P_t^{norm} = 75 \Rightarrow$  Pérdida acumulada -25 %

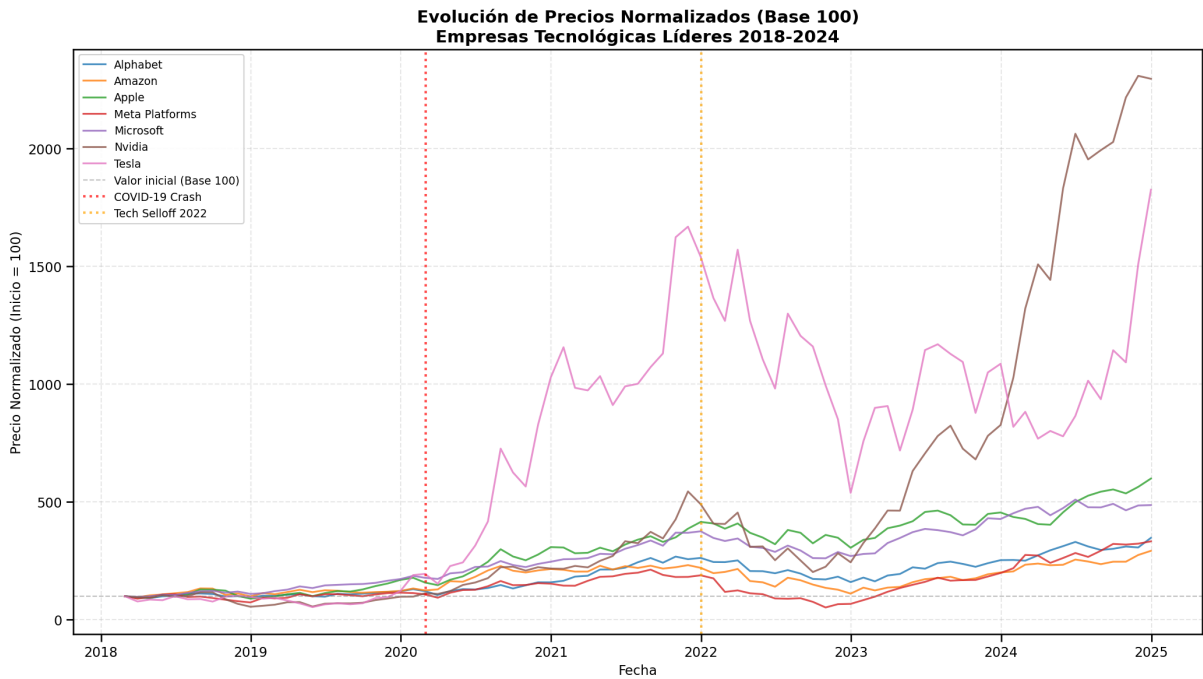


Figura 7: Series de precios normalizadas (Base 100) para principales empresas tecnológicas. Líneas verticales marcan COVID-19 crash (marzo 2020) y Tech Selloff (2022). La divergencia revela heterogeneidad de desempeño.

📊 Resultado

El análisis de rendimiento total durante el período Feb 2018 – Dic 2024 (6.92 años) revela:

Empresa	Rendimiento Total	CAGR
Nvidia	+2,196.0 %	57.3 %
Tesla	+1,725.1 %	52.2 %
Apple	+499.4 %	29.6 %
Microsoft	+386.7 %	25.7 %
Alphabet	+247.7 %	19.7 %
Meta Platforms	+232.8 %	19.0 %
Amazon	+192.6 %	16.8 %

Nvidia y Tesla destacan con rendimientos excepcionales superiores a 1,700 %, impulsados por el auge de IA y vehículos eléctricos.

## 1.6 Análisis de Correlación

### Diversificación y Correlación

El principio de diversificación establece que combinar activos imperfectamente correlacionados reduce el riesgo sin sacrificar retorno:

$$\sigma_p^2 = \sum_i w_i^2 \sigma_i^2 + \sum_i \sum_{j \neq i} w_i w_j \sigma_i \sigma_j \rho_{ij} \quad (12)$$

El beneficio de diversificación surge cuando  $\rho_{ij} < 1$ . Máximo beneficio con  $\rho < 0$ .

### Coefficiente de Correlación de Pearson

$$\rho_{ij} = \frac{\text{Cov}(R_i, R_j)}{\sigma_i \cdot \sigma_j} = \frac{\sum_{t=1}^T (R_{i,t} - \bar{R}_i)(R_{j,t} - \bar{R}_j)}{\sqrt{\sum_t (R_{i,t} - \bar{R}_i)^2} \cdot \sqrt{\sum_t (R_{j,t} - \bar{R}_j)^2}} \quad (13)$$

El coeficiente  $\rho \in [-1, 1]$  mide intensidad y dirección de relación lineal.

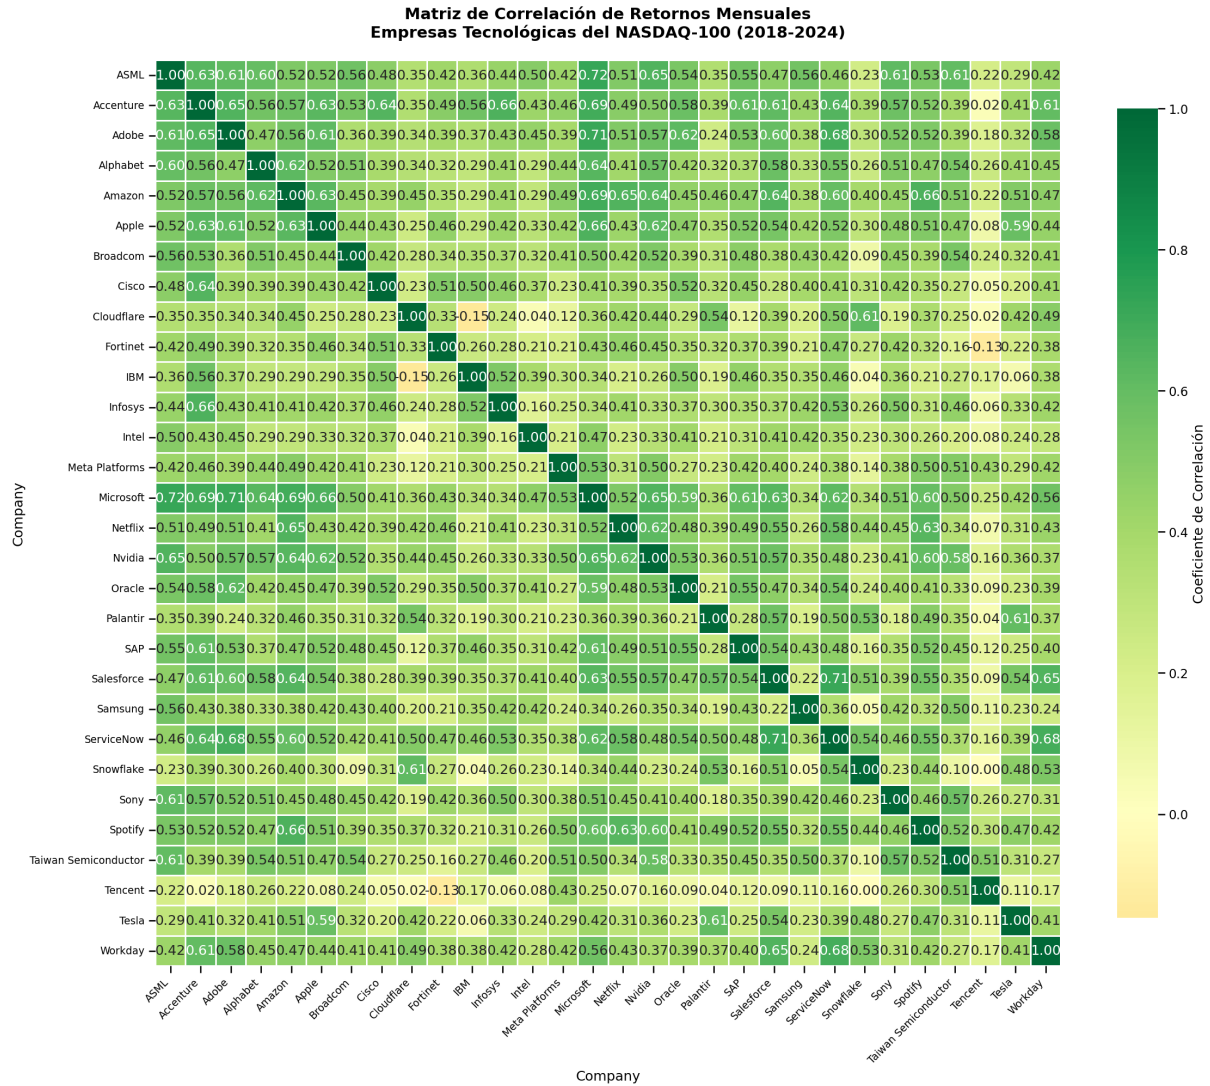


Figura 8: Matriz de correlación de retornos mensuales entre las 30 empresas. Colores cálidos indican correlaciones positivas altas; colores fríos indican bajas o negativas. Diagonal principal: autocorrelación = 1.

### ⊙ Resultado

El análisis de correlación entre las 30 empresas (435 pares únicos) reveló:

#### Pares con mayor correlación:

1. ASML – Microsoft:  $\rho = 0,721$
2. Salesforce – ServiceNow:  $\rho = 0,711$
3. Adobe – Microsoft:  $\rho = 0,709$
4. Amazon – Microsoft:  $\rho = 0,690$
5. Accenture – Microsoft:  $\rho = 0,688$

#### Pares con menor correlación:

1. Cloudflare – IBM:  $\rho = -0,147$
2. Fortinet – Tencent:  $\rho = -0,125$

3. Snowflake – Tencent:  $\rho = 0,001$
4. Cloudflare – Tencent:  $\rho = 0,021$
5. Accenture – Tencent:  $\rho = 0,024$

**Distribución:** Alta ( $\rho \geq 0,7$ ): 3 pares (0.7 %) | Media ( $0,4 \leq \rho < 0,7$ ): 227 pares (52.2 %) | Baja ( $\rho < 0,4$ ): 205 pares (47.1 %)

### Correlación Intra-Sectorial

El análisis de correlación del panel tecnológico revela:

- **Correlación promedio:**  $\rho = 0,40$  (excluyendo diagonal)
- **Rango:** desde  $\rho = -0,15$  (Cloudflare–IBM) hasta  $\rho = 0,72$  (ASML–Microsoft)
- **Clasificación:** Solo 3 pares (0.7 %) con correlación alta ( $\rho \geq 0,7$ )

Esta correlación moderada **permite cierto beneficio de diversificación** intra-sectorial, aunque limitado respecto a diversificación entre sectores.

## 1.7 Detección de Valores Atípicos (Outliers)

### Métodos de Detección de Outliers

**Método IQR (Tukey, 1977):**

$$\text{Outlier si: } x < Q_1 - 1,5 \times IQR \quad \vee \quad x > Q_3 + 1,5 \times IQR \quad (14)$$

**Método Z-score:**

$$z_i = \frac{x_i - \mu}{\sigma}, \quad \text{Outlier si } |z_i| > 3 \quad (15)$$

El método IQR es más robusto (usa cuartiles); Z-score es sensible a outliers en media/std.

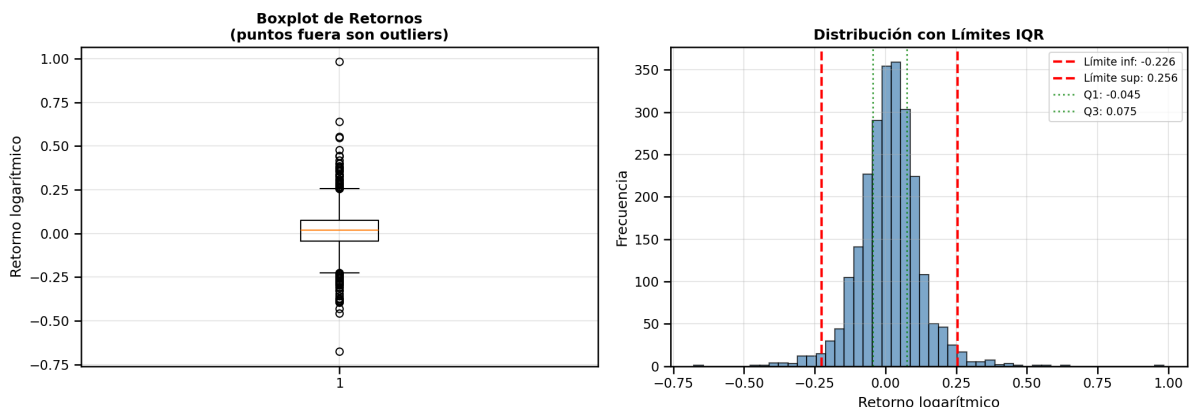


Figura 9: Análisis de outliers. Izquierda: Boxplot con outliers como puntos individuales. Derecha: Histograma con límites IQR superpuestos delimitando región típica.

### ⊙ Resultado

La detección de outliers en los retornos del panel reveló:

- **Método IQR:** 84 outliers detectados (3.50 % de las observaciones)
- **Método Z-score** ( $|z| > 3$ ): 33 outliers detectados (1.37 %)
- **Límites IQR:**  $Q_1 = -4,53 \%$ ,  $Q_3 = +7,51 \%$ ,  $IQR = 12,04 \%$
- **Rango válido:**  $[-22,59 \%, +25,57 \%]$

**Outliers más extremos positivos:** Palantir +98.4 % (Nov 2020), Palantir +64.1 % (May 2023), Tesla +55.5 % (Ago 2020).

**Outliers más extremos negativos:** Netflix -67,7 % (Abr 2022), Tesla -45,8 % (Dic 2022), Cloudflare -43,1 % (May 2022).

### Tratamiento de Outliers Financieros

Los outliers financieros raramente deben eliminarse. Representan frecuentemente:

- Eventos legítimos (crashes, rallies, anuncios corporativos)
- Información valiosa sobre riesgo de cola (*tail risk*)
- Señales de cambio de régimen

Eliminarlos subestimaría el riesgo real.

## 1.8 Análisis de Momentos Estadísticos

### Los Cuatro Momentos de una Distribución

1. **Media** (Primer momento):  $\mu = E[R]$

2. **Varianza** (Segundo momento central):  $\sigma^2 = E[(R - \mu)^2]$

3. **Asimetría / Skewness** (Tercer momento estandarizado):

$$\gamma_1 = E \left[ \left( \frac{R - \mu}{\sigma} \right)^3 \right] \quad (16)$$

$\gamma_1 < 0$ : Sesgo negativo (cola izquierda más larga)

4. **Curtosis** (Cuarto momento estandarizado):

$$\gamma_2 = E \left[ \left( \frac{R - \mu}{\sigma} \right)^4 \right] - 3 \quad (17)$$

$\gamma_2 > 0$ : Leptocúrtica (colas pesadas, eventos extremos frecuentes)

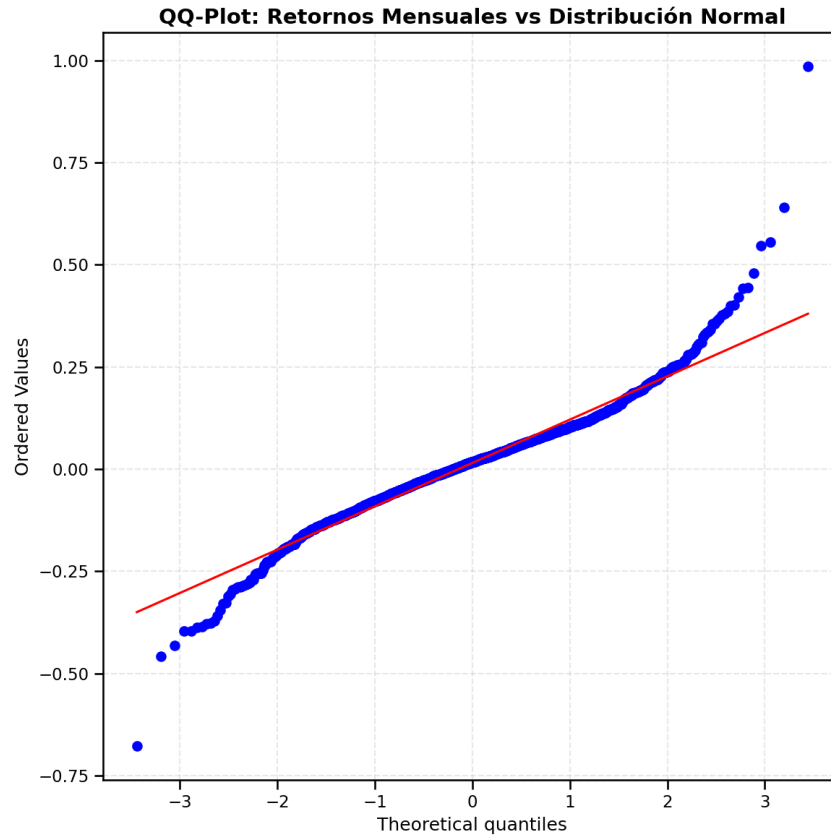


Figura 10: Gráfico Q-Q comparando cuantiles empíricos con normal teórica. Puntos sobre diagonal indicarían normalidad. Desviaciones en colas revelan leptocurtosis característica.

### Test de Jarque-Bera

Propuesto por Carlos M. Jarque y Anil K. Bera (*International Statistical Review*, 1987), este test evalúa conjuntamente asimetría y curtosis para contrastar normalidad:

$$JB = \frac{n}{6} \left( \gamma_1^2 + \frac{\gamma_2^2}{4} \right) \quad (18)$$

Bajo  $H_0$  (normalidad),  $JB \sim \chi^2(2)$ . Si el p-valor  $< 0,05$ , se rechaza la hipótesis de normalidad al 5 % de significancia.

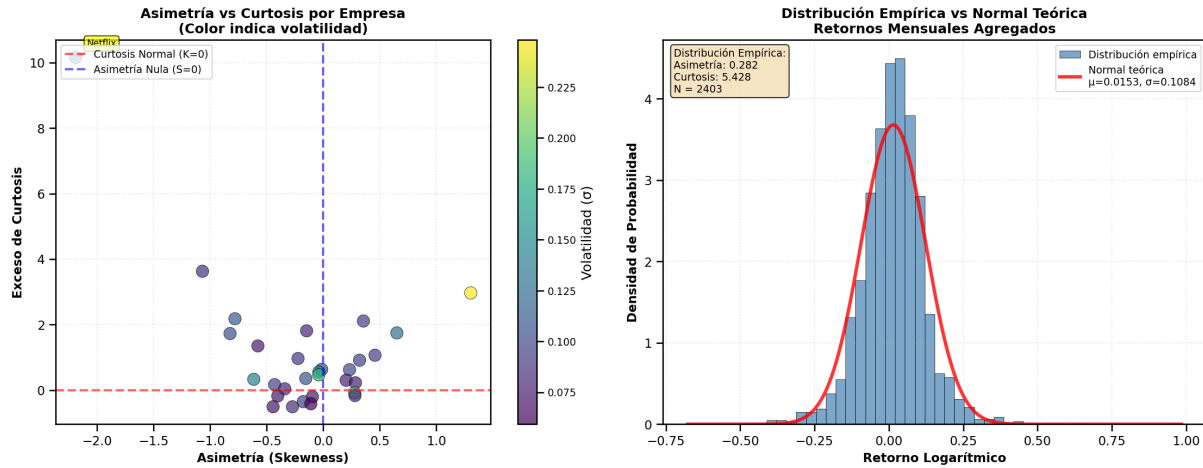


Figura 11: Análisis distribucional. Evaluación de asimetría, curtosis y desviación respecto a normalidad para el conjunto de empresas.

### ✓ Hallazgo Clave

El análisis de momentos estadísticos del panel tecnológico revela:

- **Asimetría promedio:**  $\gamma_1 = -0,15$  (sesgo negativo leve)
- **Curtosis promedio:**  $\gamma_2 = 1,06$  (exceso de curtosis, colas pesadas)
- **Leptocurtosis:** 22 de 30 empresas (73.3%) presentan  $\gamma_2 > 0$
- **Normalidad:** 10 de 30 empresas (33.3%) rechazan normalidad (Test Jarque-Bera,  $\alpha = 0,05$ )

La empresa con mayor curtosis es **Netflix** ( $\gamma_2 = 10,16$ ), seguida de SAP ( $\gamma_2 = 3,63$ ) y Palantir ( $\gamma_2 = 2,97$ ). Las empresas que rechazan normalidad son: Meta, Taiwan Semiconductor, Netflix, IBM, Palantir, Intel, Broadcom, SAP, Infosys y Snowflake.

## 1.9 Análisis de Drawdown

### Drawdown y Maximum Drawdown

El drawdown cuantifica la caída desde máximos históricos:

$$DD_t = \frac{P_t - \max_{s \leq t} P_s}{\max_{s \leq t} P_s} \times 100\% \quad (19)$$

El **Maximum Drawdown (MDD)** es la peor caída observada:

$$MDD = \min_t DD_t \quad (20)$$

Propiedades:  $DD_t \leq 0$  siempre;  $DD_t = 0$  en máximo histórico.

## Asimetría de la Recuperación

Las pérdidas requieren ganancias proporcionalmente mayores para recuperarse:

### Pérdida Ganancia para recuperar

-10 %	+11.1 %
-25 %	+33.3 %
-50 %	+100 %
-75 %	+300 %

Por esto la gestión del riesgo de caída es más importante que maximizar retorno.

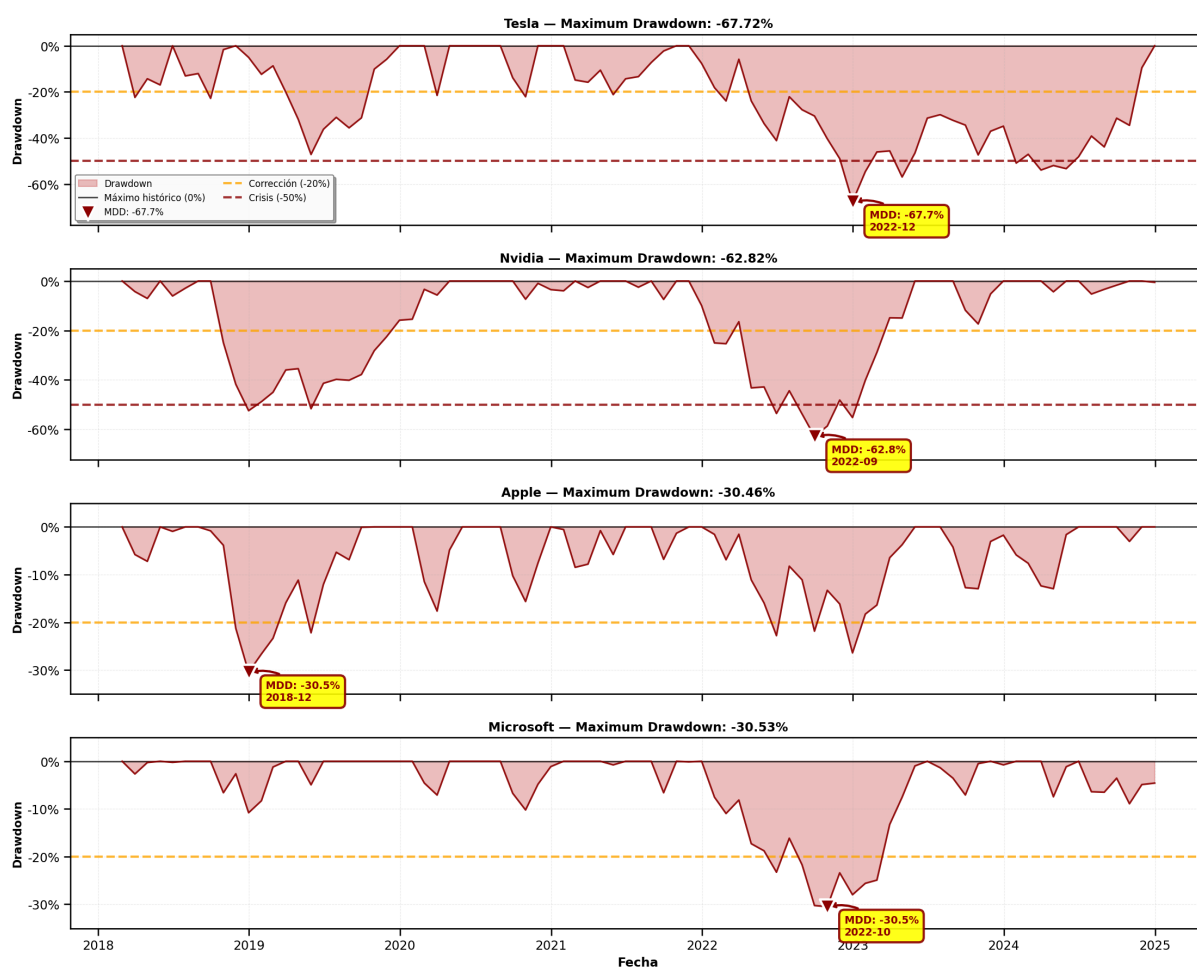


Figura 12: Series de drawdown para empresas seleccionadas (Tesla, Nvidia, Apple, Microsoft). Área roja: magnitud del drawdown. Líneas horizontales: umbrales  $-20\%$  (corrección) y  $-50\%$  (crisis).

## ⊙ Resultado

El análisis de Maximum Drawdown (MDD) para las empresas principales reveló:

Empresa	MDD	Tiempo bajo agua	Retorno para recuperar
Tesla	−67,72 %	67 meses (80.7 %)	+209.8 %
Nvidia	−62,82 %	54 meses (65.1 %)	+169.0 %
Microsoft	−30,53 %	48 meses (57.8 %)	+43.9 %
Apple	−30,46 %	56 meses (67.5 %)	+43.8 %

Las empresas de alto crecimiento (Tesla, Nvidia) experimentaron caídas superiores al 60 %, mientras que las empresas maduras (Apple, Microsoft) limitaron sus pérdidas máximas a aproximadamente 30 %.

### Calmar Ratio

Mide eficiencia del retorno ajustada por riesgo de pérdida máxima:

$$\text{Calmar Ratio} = \frac{CAGR}{|MDD|} \quad (21)$$

donde  $CAGR$  es Tasa de Crecimiento Anual Compuesta. Ratio > 1: excelente.

## 1.10 Análisis de Cambio Estructural: Pre/Post COVID-19

### Análisis de Regímenes

La pandemia afectó los mercados tecnológicos a través de múltiples canales:

1. **Shock inicial:** Caída abrupta marzo 2020 ante parálisis económica
2. **Transformación digital:** Trabajo remoto, e-commerce, cloud beneficiaron al sector
3. **Política monetaria:** Tasas cercanas a cero impulsaron valuaciones
4. **Reversión 2022:** Normalización monetaria y corrección de excesos

División temporal: **Pre-COVID** (Ene 2018 – Feb 2020) vs **Post-COVID** (Mar 2020 – Dic 2024)

### Tests de Comparación

**Test t de Welch** (medias con varianzas desiguales):

$$t = \frac{\bar{R}_{post} - \bar{R}_{pre}}{\sqrt{\frac{s_{post}^2}{n_{post}} + \frac{s_{pre}^2}{n_{pre}}}} \quad (22)$$

**Test de Levene:** Homogeneidad de varianzas.  $H_0: \sigma_{pre}^2 = \sigma_{post}^2$

P-valor < 0,05 indica cambio estadísticamente significativo.

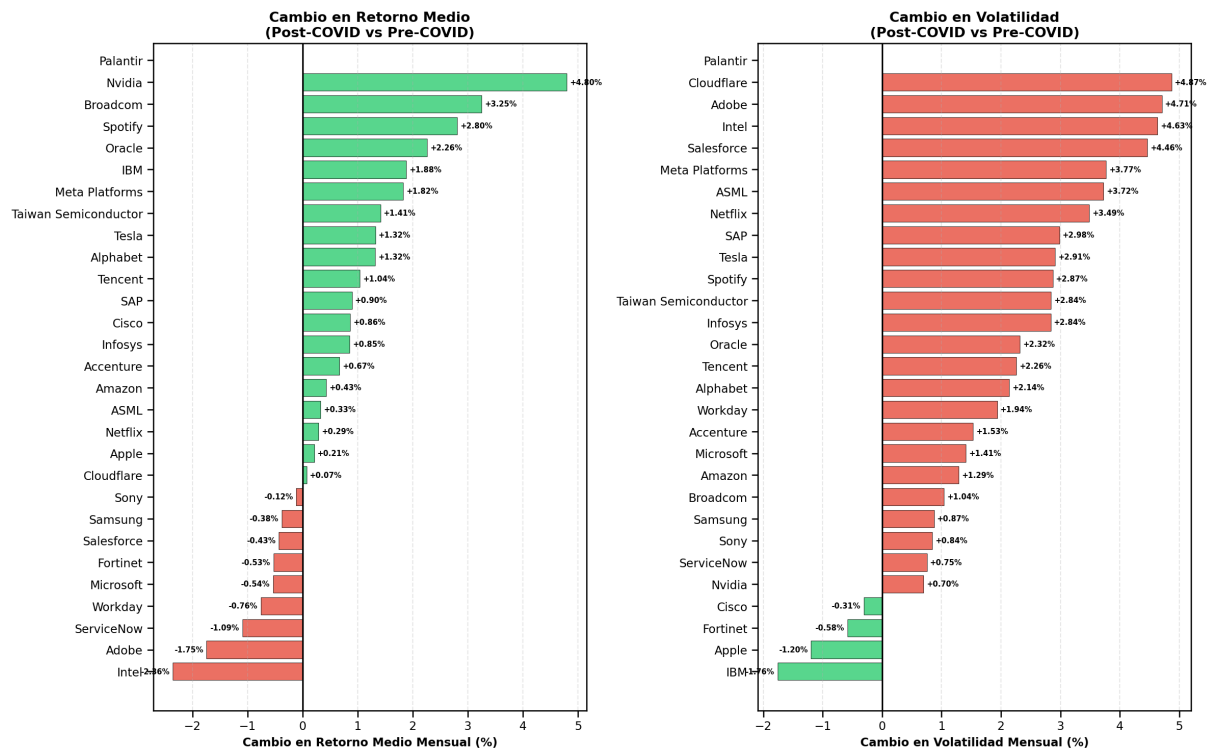


Figura 13: Cambios en retorno medio y volatilidad (Post-COVID vs Pre-COVID). Verde: mejora; Rojo: deterioro.

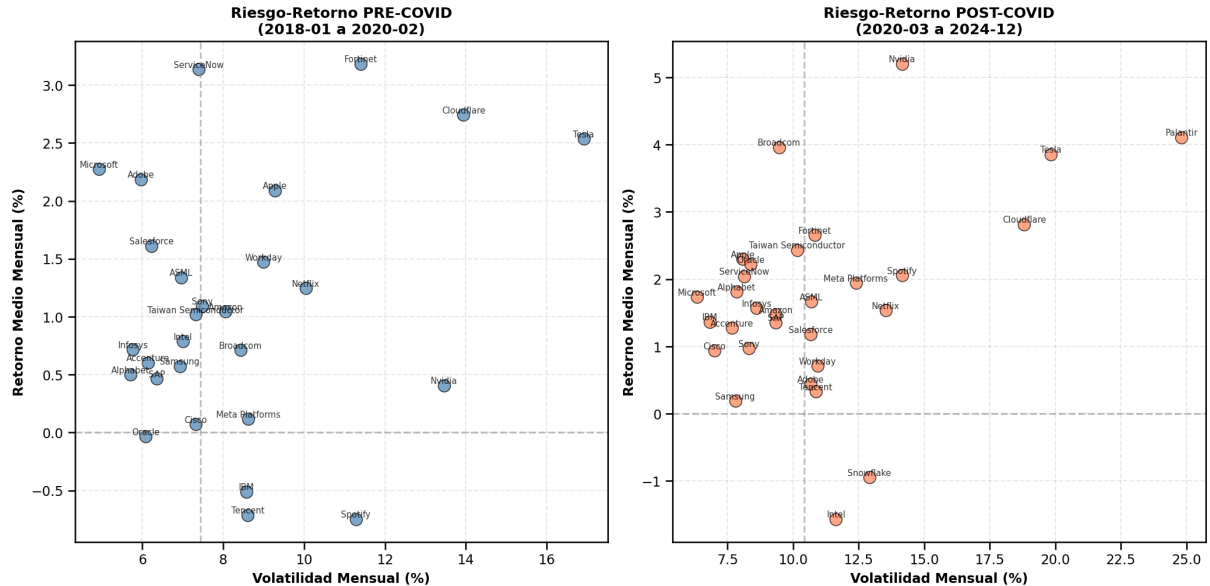


Figura 14: Diagrama riesgo-retorno segmentado por período. Visualización de migración en el espacio riesgo-retorno tras shock pandémico.

### ✓ Hallazgo Clave

El análisis de cambio estructural pre/post COVID-19 revela:

- **Retorno medio:** 19 de 30 empresas (63.3%) mejoraron post-COVID

- **Volatilidad:** 24 de 30 empresas (80.0 %) aumentaron volatilidad post-COVID
- **Pre-COVID** (677 obs.): Retorno medio promedio 1.07 %, volatilidad promedio 8.40 %
- **Post-COVID** (1,726 obs.): Retorno medio promedio 1.72 %, volatilidad promedio 11.01 %
- **Test de Welch:** Ninguna empresa (0 %) muestra cambio significativo en media ( $\alpha = 0,05$ )
- **Test de Levene:** Solo 3 empresas (10.7 %) — ASML, Salesforce, Adobe — muestran cambio significativo en varianza ( $\alpha = 0,05$ )

El COVID-19 representó un punto de quiebre estructural para **algunas** empresas del sector, principalmente en términos de volatilidad más que en retorno promedio.

**Nota:**

**Empresas con mayor mejora post-COVID:** Nvidia (+4.80 % mensual), Broadcom (+3.25 %), Spotify (+2.80 %), Oracle (+2.26 %).

**Empresas con peor desempeño post-COVID:** Intel (−2,36 % mensual), Adobe (−1,75 %), ServiceNow (−1,09 %).

La ausencia de cambios estadísticamente significativos en media (Test de Welch) se debe a la alta variabilidad intra-período que domina sobre las diferencias entre períodos.

## 1.11 Síntesis del Análisis Exploratorio

### Conclusiones del Análisis Exploratorio

1. **Calidad de datos:** Dataset con 0 % de valores faltantes en todas las columnas. Cuatro empresas (Palantir, Snowflake, Cloudflare, Spotify) con menos de 83 observaciones debido a IPOs posteriores a febrero 2018.
2. **Distribución de retornos:** El 73.3 % de empresas presenta leptocurtosis ( $\gamma_2 > 0$ ). Asimetría promedio de  $-0,15$  y curtosis promedio de  $1,06$ . Netflix destaca con curtosis extrema ( $\gamma_2 = 10,16$ ).
3. **Outliers:** 3.50 % de observaciones clasificadas como outliers (método IQR). Eventos extremos concentrados en 2020 (COVID crash/rally) y 2022 (tech selloff).
4. **Correlación:** Promedio  $\rho = 0,40$ , con rango  $[-0,15, 0,72]$ . Solo 3 pares con  $\rho \geq 0,7$  (ASML–Microsoft, Salesforce–ServiceNow, Adobe–Microsoft).
5. **Drawdowns:** Tesla ( $-67,72\%$ ) y Nvidia ( $-62,82\%$ ) con MDD superiores al 60 %. Apple y Microsoft limitaron pérdidas máximas a  $\approx 30\%$ .
6. **Impacto COVID-19:** 63.3 % de empresas mejoraron retorno medio post-COVID, pero 80.0 % aumentaron volatilidad. Ninguna empresa muestra cambio significativo en media (Test de Welch), pero 3 empresas (ASML, Salesforce, Adobe) muestran cambio significativo en varianza (Test de Levene).

## Referencias Bibliográficas

---

- [1] Campbell, J. Y., Lo, A. W., & MacKinlay, A. C. (1997). *The Econometrics of Financial Markets*. Princeton University Press. ISBN: 978-0691043012.
- [2] Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236. DOI: 10.1080/713665670.
- [3] Hull, J. C. (2018). *Options, Futures, and Other Derivatives* (10th ed.). Pearson Education. ISBN: 978-0134472089.
- [4] Jarque, C. M., & Bera, A. K. (1987). A test for normality of observations and regression residuals. *International Statistical Review*, 55(2), 163–172. DOI: 10.2307/1403192.
- [5] Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91. DOI: 10.2307/2975974.
- [6] Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592. DOI: 10.1093/biomet/63.3.581.
- [7] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley Publishing Company. ISBN: 978-0201076165.